

VIGNETTE 01 / 05

Le bon modèle

Commencer petit, monter si nécessaire.

Commencer petit, monter si nécessaire

PETIT

flash / léger — la plupart des tâches

ex. GLM 5.3 Flash, Qwen 3.8 Flash Next

MOYEN

à la frontière — quand la tâche résiste

ex. GLM 5.3, Mistral Medium 3.5

FRONTALIER

Vraiment difficile — rarement nécessaire

ex. Claude Opus 5.5, GPT 6 Sol

- Coût, latence et empreinte varient du simple au centuple
- Le plus gros modèle n'est pas toujours le meilleur

VIGNETTE 01 — LE BON MODÈLE

L'agent peut choisir lui-même

« Analyse la tâche en cours et propose le plus petit modèle capable de la résoudre. »

- Demandez-lui d'évaluer la tâche avant de coder
- Un modèle « flash » suffit souvent — économique et rapide

catalogue : cortecs.ai/serverlessModels

→ Retour au travail — essayez `/models` maintenant.

